

F09 - Hashtabell, Prioritetskö, Hög

5DV149 Datastrukturer och algoritmer

Kapitel 13.5, 14.5–14.8

Niclas Börnin

niclas.borlin@cs.umu.se

2024-02-08 Tor

- ▶ Hashtabell
- ▶ Prioritetskö:
 - ▶ Modell
 - ▶ Organisation
 - ▶ Konstruktioner
 - ▶ Listor
 - ▶ *Heap* (Hög)


Långsam sökning i Tabell

Hashtabell

- ▶ Problem: Sökningen i en generell Tabell är $O(n)$
- ▶ Vi vill hitta ett **snabbare** sätt att söka

Principskiss Hashtabell

► Öppen hashtabell



► Sluten hashtabell

0	127
1	21
2	32
3	43
4	92
5	127
6	127
7	127
8	28
9	127

Tabell som Fält

- Om vi kan konstruera tabellen med ett **Fält** blir operationerna **Lookup**, **Insert**, **Remove** $O(1)$

Tabell-funktion	Fält-funktioner
Lookup	Has-value och Inspect-value
Insert	Set-value
Remove	Set-value

- En **teoretisk** begränsning är att **nyckeltypen** måste gå att använda som **index**
- En **praktisk** begränsning är att **grundmängden** för nycklarna kan bli **stor**
 - Ex. nyckelmängden 32-bitars heltal kräver ett Fält med 4 miljarder element

Hashtabell

- En **Hashtabell** är en variant på tabell som har följande egenskaper
 1. I princip lika **generell** som Tabell
 - Lite större krav på indextypen
 2. I princip lika **snabb** som Fält
 - Alla operationer går att göra i $O(1)$ tid, med vissa begränsningar
 3. Kräver **mycket mindre minne** än Fält

Hashtabell, krav på nyckeltypen

- Precis som för Tabell så kräver vi att **likhet** är definierat för nyckeltypen
- **Dessutom** kräver vi att det finns en speciell **nyckel-hashfunktion** implementerad för nyckeltypen
- Önskade egenskaper för nyckel-hashfunktionen:
 - Nyckel-hashfunktionen är definierad för **alla** objekt **k** av nyckeltypen
 - Nyckel-hash-funktionen tar ett objekt **k** av nyckeltypen och returnerar ett **heltal**
 - Nyckel-hash-funktionen bör vara **snabb** att beräkna
 - Nyckel-hash-värdena för **olika** nycklar bör vara **olika**
- Begränsning
 - Vi har i princip ingen begränsning i **storlek** på heltalet
 - I praktiken brukar en fysisk datatyp bli begränsningen, t.ex. 32-bitars heltal

Gränsyta för Hashtabell

```
abstract datatype Hashtable(arg, val)
  Empty(kh: function(arg)) → Hashtable(arg, val)
  Insert(k: arg, v: val, t: Hashtable(arg, val))
    → Hashtable(arg, val)
  Iseempty(t: Hashtable(arg, val)) → Bool
  Lookup(k: arg, t: Hashtable(arg, val)) → (Bool, val)
  Remove(k: arg, t: Hashtable(arg, val))
    → Hashtable(arg, val)
  Kill(t: Hashtable(arg, val)) → ()
```

Exempel på nyckel-hashfunktion (1)

- För indextypen Sträng så är det vanligt att iterera över alla element i strängen, t.ex.

```
Algorithm String-hash(s: String)
// Compute a hash value that depends on all characters in the string
seed ← 131 // Magic number
hash ← 0
for i from 0 to length(s) - 1 do
  hash ← (hash * seed) + char-to-int(lowercase(Inspect-value(s, i)))
return hash
```

- Notera att hash-värdet kan bli stort!
 - Strängen "Jan" får hash-värdet 1831883

Exempel på nyckel-hashfunktion (2)

- För en Post bör alla relevanta fält påverka hashvärdet
- För en Post med fälten `item_number` (Heltal) och `serial_number` (Sträng) skulle nyckel-hashfunktionen kunna vara

```
Algorithm Record-hash(r: Record)
return r.item_number * String-hash(r.serial_number)
```

- Posten (1412, "LE74D") får då hash-värdet
1412 · 32033999426 = 45232007189512

Notera

- Det var vanligt att motiveringen till hashtabeller är att det är möjligt att använda **strängar** som nycklar
- Jag vill poängtera att det går att använda **vilken datatyp som helst** som nyckel, så länge en nyckel-hashfunktion finns definierad

Tabell-hashfunktion

- ▶ Alla hashtabeller är konstruerade med något sorts **Fält**
- ▶ Vi skulle i princip kunna välja att använda nyckel-hash-värdena direkt som **index** i Fältet
 - ▶ Det slösar dock stora mängder **minne**
- ▶ För att slippa skapa onödigt **stora** Fält kommer vi att använda en **tabell-hashfunktion**
- ▶ Tabell-hashfunktionen avbildar en **stor** indextyp A på en **mindre** indextyp B, t.ex.
 - ▶ A=32-bitars heltal, B=8-bitars heltal
 - ▶ A=heltal i intervallet 0–99, B=heltal i intervallet 0–6
- ▶ Vi lagrar sedan våra tabellvärden i ett Fält med indextyp B

Tabell-hashfunktion, önskade egenskaper

- ▶ En hashfunktion $h(a)$ bör följande egenskaper:
 1. Funktionen kan avbilda **alla** element a i A på **något** element $b = h(a)$ i B
 2. De avbildade elementen $b = h(a)$ bör ha en bra **spridning** för de förväntade värdena i A
 3. Funktionen är **snabb** att beräkna för alla a
- ▶ För exemplet postnummer med intervallen A=10000–99999, B=0–99 skulle hashfunktionen

$$h(x) = \lfloor x/1000 \rfloor$$

ha egenskap 1 och 3 men inte 2:

- ▶ Inget värde avbildas på 0–9
- ▶ Fler värden avbildas troligtvis på 11 än 98 (fler postnummer 11xxx än 98xxx)

Operatörn mod

- ▶ Den överlägset vanligaste tabell-hashfunktionen använder operatörn **mod** som beräknar **heltalsrest** vid division
 - ▶ Operatörn är snabb och har **bra spridningsegenskaper** på många indata
 - ▶ För Heltal $a, n > 0$ så avbildar

$$h(a) = a \bmod n,$$

alla heltalen a på heltalen $[0, 1, \dots, n-1]$

▶ Ex.

0 mod 4 = 0,	4 mod 4 = 0,
1 mod 4 = 1,	5 mod 4 = 1,
2 mod 4 = 2,	6 mod 4 = 2,
3 mod 4 = 3,	7 mod 4 = 3,

- ▶ Om a är ett nyckel-hash-värde och n är storleken på fältet så kan $h(a) = a \bmod n$ användas som index i hashtabellen (fältet)

Summering (1)

- ▶ Nyckel-hashfunktionen

$$a = n(k) \in A$$

ger oss **generalitet** för nyckeltypen men riskerar att ge stora hash-värden

- ▶ Tabell-hashfunktionen

$$h(a) = h(n(k)) \in B$$

reducerar nyckel-hashvärdena till ett litet intervall och ger oss lågt **minnesutnyttjande**

Summering (2)

- ▶ Återstår att visa att funktionerna `Lookup`, `Insert`, `Remove` går att implementera i $O(1)$ tid
- ▶ Alla funktionerna har behov av att hitta en plats (**index**) i hashtabellen (fältet) givet en **nyckel** k
 - ▶ Nyckeln k **duger inte som index**, då k typiskt inte är av indextypen för fältet
 - ▶ Nyckel-hash-värdet $h(k)$ är ett heltal, men kan vara **för stort**
 - ▶ Tabell-hash-värdet $h(h(k))$ går att använda som index, men flera nycklar kan avbildas på **samma hashvärde**
 - ▶ Detta kallas för en **kollision**
 - ▶ Vi kommer att använda oss av en **sökalgoritm** som hanterar kollisioner

Kollisionshantering

Förenkling

- ▶ När vi diskuterar kollisionshantering kommer vi att använda nyckeltypen Heltal dvs. nyckel-hashfunktionen är **identitetsfunktionen**

```
Algorithm Int-hash(i: Int)
// The hash value for an integer is the value itself
return i
```

- ▶ Vi kommer också att använda **nyckelvärdet** som **tabellvärde**
 - ▶ I princip implementera ett Lexikon
- ▶ Senare kommer vi att titta på exempel för mer **generella** nyckeltyper och tabeller

Kollisioner

- ▶ En **kollision** är när två nycklar avbildas på **samma** hash-värde
 - ▶ En bra hashfunktion förväntas generera "få" kollisioner
 - ▶ Kollisioner går ej att undvika **helt**
- ▶ Exempelvis skulle

$$h(x) = x \mod 10$$


avbilda nyckelvärdena 89 och 59 på index 9

- ▶ Kollisioner kan hanteras med
 1. **Sluten** hashning
 - 1.1 **Linjär** teknik
 - 1.2 **Kvadratisk** teknik
 2. **Öppen** hashning

Sluten hashning

Sluten hashning, sökning

- ▶ Vid sluten hashning används en **cirkulär**, noll-baserad **vektor** (fält) för att lagra datat
 - ▶ **Statisk** tabell med fast antal platser
 - ▶ Index i en tabell av storlek n räknas **modulo** n
 - ▶ Det första elementet följer efter det sista
- ▶ Vi kommer att behöva reservera två värden som **markörer** i tabellen
 - ▶ Värdet `HASH_EMPTY` kommer att användas som en markör att platsen är **ledig**
 - ▶ Värdet `HASH_REMOVED` kommer att användas som en markör att platsen är ledig, men att ett värde har **tagis bort** från platsen någon gång
- ▶ Markörvärdena får inte vara giltiga tabellvärden
 - ▶ Om vi vill lagra värden 0–99 i hashtabellen kan vi t.ex. välja
 - ▶ `HASH_EMPTY = 100`, `HASH_REMOVED = 101` eller
 - ▶ `HASH_EMPTY = -1`, `HASH_REMOVED = -2`



Sluten hashning, sökning med linjär teknik

- ▶ **Sökning** (**Lookup**) efter ett element k börjar på index $h(k)$ och fortsätter eventuellt **framåt**
 - ▶ Om värdet inte påträffats **före nästa lediga plats** så finns det inte i tabellen
- ▶ Vid sökning med **linjär** teknik testas följande index i sekvens:

$$\begin{aligned}
 & (h(k) + 0) \bmod n \\
 & (h(k) + 1) \bmod n \\
 & (h(k) + 2) \bmod n \\
 & \vdots \\
 & (h(k) + n - 1) \bmod n
 \end{aligned}$$

Sökning i sluten Hashtabell med linjär teknik

```

1  Algorithm Hash-table-lookup-closed-linear-simplified(x: Hashvalue, t: Hashtable)
2  // Lookup in a closed hashtable using linear collision handling.
3  // Returns True/False and optionally the index where x was found.
4  //
5  // Values are stored in a zero-indexed vector t.v of size TABLE_SIZE.
6
7  // Map hash value to the table size
8  h ← x mod TABLE_SIZE
9
10 // Check each available index
11 for i from 0 to TABLE_SIZE - 1 do
12     // Compute index with linear collision handling
13     j ← (h + i) mod TABLE_SIZE
14
15     // Inspect element at index j in the internal vector
16     e ← Array-inspect-value(t.v, j)
17     if e = x then
18         // We found the value
19         return (True, j)
20
21     if e = HASH_EMPTY then
22         // We found an empty slot; the value cannot be in the table
23         return (False, None)
24
25 // We have checked all indices without finding the value
26 return (False, None)
    
```

Sluten hashning, insättning

- ▶ Vid **insättning** av ett element görs först en **sökning**
 - ▶ Om sökningen hittar värdet så **ersätts** värdet i tabellen
 - ▶ Om sökningen **inte** hittar värdet så sätts värdet in på den första **lediga** platsen
- ▶ Vilken plats ett element hamnar på beror alltså på två saker:
 1. Dess hashvärde $h(n(k))$ och
 2. vilka värden som redan finns i tabellen

Insättning i sluten Hashtabell med linjär teknik

```
1  Algorithm Hash-table-insert-closed-linear-simplified(x: Hashvalue, t: Hashtable)
2  // Insert in a closed hashtable using linear collision handling.
3  // Returns the updated hash table.
4  //
5  // Values are stored in a zero-indexed vector t.v of size TABLE_SIZE.
6
7  // Map hash value to the table size
8  h ← x mod TABLE_SIZE
9
10 // Check each available index
11 for i from 0 to TABLE_SIZE - 1 do
12   // Compute index with linear collision handling
13   j ← (h + i) mod TABLE_SIZE
14
15   // Inspect element at index j in the internal vector
16   e ← Array-inspect-value(t.v, j)
17   if e = HASH_EMPTY or e = HASH_REMOVED then
18     // We found a free index; insert the value here
19     t.v ← Array-set-value(t.v, j, x)
20     return t
21
22 // We have checked all indices without finding an empty one
23 return Error("Could not find an empty slot")
```

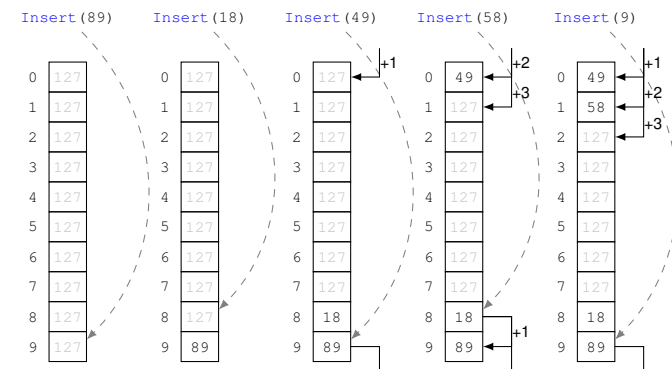
Sluten hashning, linjär teknik, insättning (1)

- ▶ Talen $\{0, \dots, 125\}$ ska lagras i en hashtabell av storlek 10
 - ▶ Vi har alltså hashfunktionen
$$h(x) = x \mod 10$$
- ▶ Låt 127 betyda "ledig" (HASH_EMPTY) och 126 betyda "borttagen" (HASH_REMOVED)

Sluten hashning, linjär teknik, insättning (2)


- ▶ Sätt in talen 89, 18, 49, 58, 9 med

$$h(x) = x \mod 10$$



Sluten hashning, linjär teknik, sökning

- Sök efter 49, 79, respektive 9:



Sluten hashning, borttagning

- Vid **borttagning** av ett element används samma sökalgoritm
 - Om värdet hittas i tabellen kan platsen inte lämnas **tom** (HASH_EMPTY) — då kan senare sökningar misslyckas
 - I stället sätts markören HASH_REMOVED in i tabellen

Borttagning i sluten Hashtabell med linjär teknik

```
1 Algorithm Hash-table-remove-closed-linear-simplified(x: Hashvalue, t: Hashtable)
2 // Remove in a closed hashtable using linear collision handling.
3 // Returns the updated hash table.
4 //
5 // Values are stored in a zero-indexed vector t.v of size TABLE_SIZE.
6
7 // Map hash value to the table size
8 h ← x mod TABLE_SIZE
9
10 // Check each available index
11 for i from 0 to TABLE_SIZE - 1 do
12 // Compute index with linear collision handling
13 j ← (h + i) mod TABLE_SIZE
14
15 // Inspect element at index j in the internal vector
16 e ← Array-inspect-value(t.v, j)
17 if e = x then
18 // We found the value; insert the REMOVED value
19 t.v ← Array-set-value(t.v, j, HASH_REMOVED)
20 return t
21
22 if e = HASH_EMPTY then
23 // We found an empty slot; return the unchanged table
24 return t
25
26 // We have checked all indices without finding the value; return the unchanged table
27 return t
```

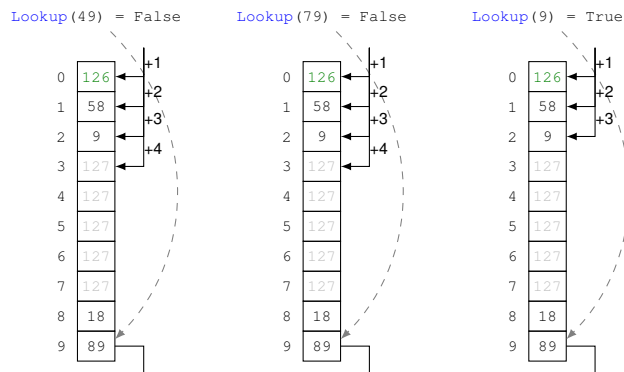
Sluten hashning, linjär teknik, borttagning

- Ta bort 49:
 - Sätt in "borttagen"-markören på 49:ans plats

Före borttagning Efter borttagning

0	49	0	126
1	58	1	58
2	9	2	9
3	127	3	127
4	127	4	127
5	127	5	127
6	127	6	127
7	127	7	127
8	18	8	18
9	89	9	89

- Sök efter 49, 79, respektive 9:



- Värstafallskomplexiteten för samtliga operationer är $O(n)$, där n är antalet element som finns insatta i tabellen
- Är dock ytterst **osannolikt**
 - Alla element måste ligga i en följd
- Under förutsättning att tabellen inte fylls mer än till en "viss del" får man i medeltal $O(1)$ för operationerna
 - Hur mycket är "till en viss del"?

Fyllnadsgrad

- En Hashtabells **fyllnadsgrad** (λ) definieras som *kvoten mellan antalet insatta element och antalet platser i tabellen*
- En tom tabell har $\lambda = 0$ och en full $\lambda = 1$

Hashtabeller, medelkomplexitet

- Det finns formler för medelantalet platser som måste prövas vid olika fyllnadsgrader
- För en halvfull tabell $\lambda = 0.5$ gäller

Operation	Medelantalet sökningar
Insättning	2.5
Misslyckad sökning	2.5
Lyckad sökning	1.5

- Slutsats:
 - Medelkomplexiteten för **Lookup**, **Insert**, **Remove** är $O(1)$ om fyllnadsgraden $\lambda < 1/2$!

Hashtabeller, klustring

- Linjär teknik ger upphov till **klustring**, dvs. att de upptagna positionerna tenderar att bli "ihopklumpade"

0	49
1	58
2	9
3	127
4	127
5	127
6	127
7	127
8	18
9	89

- Låt oss studera ett alternativ till linjär teknik...

Sluten hashning, kvadratisk teknik

- Vid sökning med **linjär** teknik testas följande index i sekvens:

$$\begin{aligned} & (h(k) + 0^1) \bmod n \\ & (h(k) + 1^1) \bmod n \\ & (h(k) + 2^1) \bmod n \\ & \vdots \\ & (h(k) + (n-1)^1) \bmod n \end{aligned}$$

- Vid sökning med **kvadratisk** teknik testas i stället följande index i sekvens:

$$\begin{aligned} & (h(k) + 0^2) \bmod n \\ & (h(k) + 1^2) \bmod n \\ & (h(k) + 2^2) \bmod n \\ & \vdots \\ & (h(k) + (n-1)^2) \bmod n \end{aligned}$$

Sökning i sluten Hashtabell med kvadratisk teknik

- Endast **en** rad modifierad i pseudokoden!

```

1  Algorithm Hash-table-lookup-closed-quadratic-simplified(x: Hashvalue, t: Hashtable)
2  // Lookup in a closed hashtable using quadratic collision handling.
3  // Returns True/False and optionally the index where x was found.
4  //
5  // Values are stored in a zero-indexed vector t.v of size TABLE_SIZE.
6
7  // Map hash value to the table size
8  h ← x mod TABLE_SIZE
9
10 // Check each available index
11 for i from 0 to TABLE_SIZE - 1 do
12   // Compute index with linear collision handling
13   j ← (h + i^2) mod TABLE_SIZE
14
15   // Inspect element at index j in the internal vector
16   e ← Array-inspect-value(t.v, j)
17   if e = x then
18     // We found the value
19     return (True, j)
20
21   if e = HASH_EMPTY then
22     // We found an empty slot; the value cannot be in the table
23     return (False, None)
24
25 // We have checked all indices without finding the value
26 return (False, None)

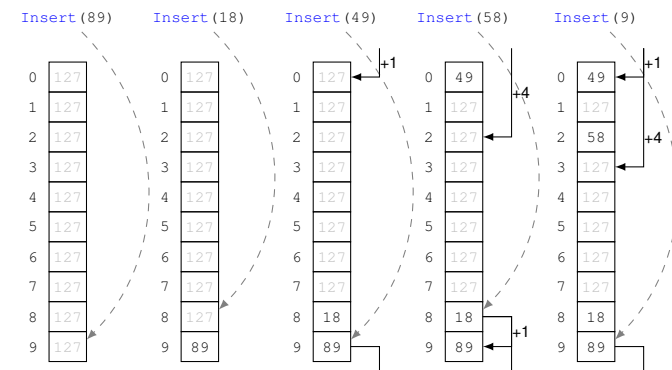
```

- Dito för **Insert** och **Remove**

Sluten hashning, kvadratisk teknik, insättning

- Sätt in talen 89, 18, 49, 58, 9 med

$$h(x) = x \bmod 10$$



Hashtabeller, klustering igen

- Klustringen är ett mindre problem för kvadratisk teknik än för linjär

Linjär

0	49
1	58
2	9
3	127
4	127
5	127
6	127
7	127
8	18
9	89

Kvadratisk

0	49
1	127
2	58
3	9
4	127
5	127
6	127
7	127
8	18
9	89

Kvadratisk teknik, problem

- Med olyckligt vald **hashfunktion** och **tabellängd** finns risk att man inte hittar en ledig plats även om den finns!

- Exempel:

- Tabellstorlek = 16, hashfunktion $h(x) = x \bmod 16$
- Efter att ha stoppat in elementen 0, 16, 32, och 64, dvs. $\lambda = 1/4$, finns ingen plats för tal med $h(x) = 0$

i	0	1	2	3	4	5	6	7
$h(x) + i^2$	0	1	4	9	16	25	36	49
$h(x) + i^2 \bmod 16$	0	1	4	9	0	9	4	1
i	8	9	10	11	12	13	14	15
$h(x) + i^2$	64	81	100	121	144	169	196	225
$h(x) + i^2 \bmod 16$	0	1	4	9	0	9	4	1

- De enda positioner som testas är 0, 1, 4, 9, ..., som redan är upptagna!

Lösning

- Om **kvadratisk** teknik används och tabellens storlek är ett **primtal** så kan ett nytt element alltid stoppas in om $\lambda < 1/2$
 - Ger **mindre klustering** än linjär hashning
 - Medelantal sonderingar för $\lambda = 1/2$:

Operation	linjär teknik	kvadratisk teknik
Insättning	2.5	2.0
Misslyckad sökning	2.5	2.0
Lyckad sökning	1.5	1.4

- Slutsats:

- Medelkomplexiteten för **Lookup**, **Insert**, **Remove** är $O(1)$ om fyllnadsgraden $\lambda < 1/2$!
- Om tabellens storlek är ett **primtal** kan **kvadratisk** teknik användas och är då snabbare än linjär teknik

Blank

Öppen hashning

- ▶ I stället för en Vektor av nyckel-värden används en k -Vektor av Lista av nyckel-värden

$$h(x) = x \mod k$$

- ▶ Vi får en **dynamisk** tabell, ingen begränsning på antalet element
- ▶ Alla element med hashvärde x hamnar i listan med index x

Insert i öppen Hashtabell

```

Algorithm Hash-table-insert-open-simplified(x: Hashvalue, t: Hashtable)
// Insert in a open hashtable. Returns the updated hash table.
// Does not check whether the value is already in the table.
//
// Values are stored in lists. The lists are stored in a zero-indexed
// vector t.v of size TABLE_SIZE.


// Map hash value to the table size
h ← x mod TABLE_SIZE

// Insert in the list at index h
l ← Array-inspect-value(t.v, h)
// Insert at the first position in the list
// Note that this may produce duplicates in the list
l ← List-insert(l, List-first(l), x)
t.v ← Array-set-value(t.v, h, l)

return t
    
```

Öppen hashning, exempel

- ▶ Sätt in talen 89, 18, 49, 58, 9 i en Hashtabell med 10 platser:



Lookup i öppen Hashtabell

```
Algorithm Hash-table-lookup-open-simplified(x: Hashvalue, t: Hashtable)
// Lookup from a open hashtable. Returns True/False.
//
// Values are stored in lists. The lists are stored in a zero-indexed
// vector t.v of size TABLE_SIZE.

// Map hash value to the table size
h ← x mod TABLE_SIZE

// Lookup in the list at index h
l ← Array-inspect-value(t.v, h)
// Iterate over the list
p ← List-first(l)
while not List-isend(l, p) do
  if List-inspect(l, p) = x then
    // We found the requested element.
    return True
  else
    // Advance in the list
    p ← List-next(l, p)

// We've checked all elements in the list.
// The element is not there.
return False
```

Remove i öppen Hashtabell

```
Algorithm Hash-table-remove(x: Hashvalue, t: Hashtable)
// Remove from a open hashtable. Returns the updated hash table.
//
// Values are stored in lists. The lists are stored in a zero-indexed
// vector t.v of size TABLE_SIZE.

// Map hash value to the table size
h ← x mod TABLE_SIZE

// Remove in the list at index h
l ← Array-inspect-value(t.v, h)
// Iterate over the list
p ← List-first(l)
while not List-isend(l, p) do
  if List-inspect(l, p) = x then
    // Remove the current element. The returned position is the
    // position AFTER the removed. Continue to traverse the list
    // since we may have duplicates.
    (l, p) ← List-remove(l, p)
  else
    // Advance in the list
    p ← List-next(l, p)

// Remove in list complete, now re-insert the list in the array
t.v ← Array-set-value(t.v, h, l)

return t
```

Öppen hashning (3)

- ▶ Värsta fallskomplexitet:
 - ▶ $O(n)$ för alla operationer (alla element i samma lista), där n är antalet insatta element
- ▶ Medelfallskomplexitet:
 - ▶ Insättning och misslyckad sökning blir n/k
 - ▶ Lyckad sökning blir ungefär $n/2k$
- ▶ Tumregel: **Maximalt $2k$ element** bör sättas in

Mer avancerade hashfunktioner

- ▶ Mer avancerade hashfunktioner kommer från talteori, t.ex.

$$h(x) = ((c_1 x + c_2) \bmod p) \bmod m,$$

- ▶ divisorn p är ett stort primtal $> m$, t.ex. 1048583,
 - ▶ konstanterna c_1 och c_2 är heltal > 0 och $< p$.
- ▶ Ännu mer avancerade
 - ▶ md5 (<https://en.wikipedia.org/wiki/MD5>)
 - ▶ SHA-1, SHA-2 (<https://en.wikipedia.org/wiki/Shasum>)
 - ▶ kryptografiska

Tabell som Hashtabell (1)

- ▶ I exemplen har vi hittills använt **heltal** som nycklar och tabellvärden
 - ▶ I princip implementerat ett **Lexikon**
 - ▶ Dessutom har inga exempel innehållit **hash-dubletter** (olika nycklar som genererar samma hash-värde)

Tabell som Hashtabell (2)

- ▶ Följande exempel visar mer realistiska Tabell-operationer
 - ▶ Vi använder en **nyckel-hashfunktion** (Key-hash-value) för att beräkna ett hashvärde från ett nyckelvärd
 - ▶ Vi använder **mod** för att trunkera nyckel-hashvärdet så det rymms i Hashtabellen
 - ▶ För att kunna hantera hash-dubletter jämför vi **både** hash-värden **och** nyckel-värden (Key-compare) för att hitta en match
 - ▶ Vi lagrar **tabellvärden** i Tabellen
- ▶ Tabellen är konstruerad som en **post** (*record*) med ett enda fält (*field*) **v** som är ett fält (*array*)
 - ▶ Varje **element** som är lagrat i fältet är en **post med tre fält**:

hash nyckel-hash-värdet
key nyckel-värdet
value tabell-värdet

Sluten hashning, linjär teknik, insert

```
Algorithm Hash-table-closed-insert-linear(k: Key, v: Value, t: Hashtable)
// Insert the key-value pair (k, v) in the hashtable t. If the key is
// already in the table, replace the value. Returns the modified table.

// Compute the size of the hash table
size ← High(t.v) - Low(t.v) + 1
// Use the user-defined hash function to compute the key hash value
key-hash ← Key-hash-value(k)
// Map to the table size
h ← key-hash mod size

// Check each available index
for i from 0 to size - 1 do
    // Compute index with linear technique to handle collisions
    p ← (h + i) mod size
    // Inspect element at index p in the internal vector
    e ← Array-inspect-value(t.v, p)
    if e.hash = HASH_EMPTY or e.hash = HASH_REMOVED then
        // We've found a free slot; insert the value here
        r ← Create-record("hash", key-hash, "key", key, "value", v)
        t.v ← Array-set-value(t.v, p, r)
        return t
    if e.hash = key-hash then
        // We've found the hash value, now compare the actual keys
        if Key-compare(k, e.key) then
            // The keys match; replace the value associated with the key
            r ← Create-record("hash", key-hash, "key", key, "value", v)
            t.v ← Array-set-value(t.v, p, r)
            return t

// We have checked all indices without finding an empty slot
return Error("Could not find an empty slot")
```

Sluten hashning, linjär teknik, lookup

```
Algorithm Hash-table-lookup-closed-linear(k: Key, t: Hashtable)
// Look up the key k in the hashtable t.
// If the key is found, returns (True, v), where v is the table value associated with k.
// Otherwise returns (False, None)

// Compute the size of the hash table
size ← High(t.v) - Low(t.v) + 1

// Use the user-defined hash function to compute the key hash value
key-hash ← Key-hash-value(k)
// Map to the table size
h ← key-hash mod size

// Check each available index
for i from 0 to size - 1 do
    // Compute index with linear technique to handle collisions
    p ← (h + i) mod size
    // Inspect element at index p in the internal vector
    v ← Array-inspect-value(t.v, p)
    if v.hash = HASH_EMPTY then
        // We found an empty slot; the key cannot be in the table
        return (False, None)
    if v.hash = key-hash then
        // We've found the hash value, now compare the actual keys
        if Key-compare(k, v.key) then
            // The keys match; return the value associated with the key
            return (True, v.value)

// We have checked all indices without finding a matching key
return (False, None)
```

Sluten hashning, linjär teknik, remove

```

Algorithm Hash-table-closed-remove-linear(k: Key, t: Hashtable)
// Remove the key-value pair with the key k from the hashtable t. Returns the modified table.

// Compute the size of the hash table
size ← High(t.v) - Low(t.v) + 1

// Use the user-defined hash function to compute the "object" hash value
key-hash ← Key-hash-value(k)
// Map to the table size
h ← key-hash mod size

// Check each available index
for i from 0 to size - 1 do
    // Compute index with linear technique to handle collisions
    p ← (h + i) mod size

    // Inspect element at index p in the internal vector
    e ← Array-inspect-value(t.v, p)
    if e.hash = key-hash then
        // We've found the hash value, now compare the actual keys
        if Key-compare(k, e.key) then
            // The keys match; mark the element as REMOVED
            r ← Create-record("hash", HASH_REMOVED, "key", None, "value", None)
            t.v ← Array-set-value(t.v, p, r)
            return t

return Error("Did not find the key")
    
```

Exempel, Month-to-days, sluten hashning (1)

Key	Jan	Feb	Mar	Apr	May	Jun
Hash	1831883	1763751	1883370	1679403	1883377	1834503
mod 19	17	0	14	12	2	15

Key	Jul	Aug	Sep	Oct	Nov	Dec
Hash	1834501	1680047	1986858	1917956	1902369	1729430
mod 19	13	10	9	1	13	12

Exempel, Month-to-days, sluten hashning (2)

► Linjär teknik

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
Feb	Oct	May							Sep	Aug		Apr	Jul	Mar	Jun	Nov	Jan	Dec
28	31	31							31	31		30	31	31	30	30	31	31

► Kvadratisk teknik

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
Feb	Oct	May	Nov						Sep	Aug		Apr	Jul	Mar	Jun	Dec	Jan	
28	31	31	30						31	31		30	31	31	30	31	31	

► Jämförelse

	Antal lediga sekvenser	Lyckad sökning	Misslyckad sökning
Linjär	2	21/12=1.75	77/19=4.05
Kvadratisk	3	17/12=1.42	53/19=2.79

Exempel, Month-to-days, öppen hashning

Size	Hash Mod	Jan	Feb	Mar	Apr	May	Jun
6		1831883	1763751	1883370	1679403	1883377	1834503
		5	3	0	3	1	3

Size	Hash Mod	Jul	Aug	Sep	Oct	Nov	Dec
6		1834501	1680047	1986858	1917956	1902369	1729430
		1	5	0	2	3	2

► Öppen hashning, storlek 6

0	Sep	Mar		
1	Jul	May		
2	Dec	Oct		
3	Nov	Jun	Apr	Feb
4				
5	Aug	Jan		

- Lyckad sökning: $22/12 = 1.83$
- Misslyckad sökning: $15/6 = 2.5$

Prioritetskö

- ▶ Modell:
 - ▶ Patienterna på en akutmottagning kommer in i en viss tidsordning men behandlas utifrån en **annan** ordning
- ▶ Organisation:
 - ▶ En **mängd** vars grundmängd är **linjärt ordnad** av en **prioritetsordning**:
 - ▶ Avläsningar och borttagningar görs endast på det element som har **högst prioritet**
 - ▶ Andra mängdoperationer är inte aktuella

Informell specifikation av prioritetskö (1)

```
abstract datatype Pqueue(val, R)
  Empty() → Pqueue(val, R)
  Iempty(p: Pqueue(val, R)) → Bool
  Insert(v: val, p: Pqueue(val, R)) → Pqueue(val, R)
  Inspect-first(p: Pqueue(val, R)) → val
  Delete-first(p: Pqueue(val, R)) → Pqueue(val, R)
  Kill(p: Pqueue(val, R)) → ()
```

- ▶ R är **relationen** för prioritetsordningen
 - ▶ Om t.ex. R är “<” så är “**a R b**” sann om **a < b**

Informell specifikation av prioritetskö (2)

- ▶ **Empty** returnerar en tom prioritetkö
- ▶ **Iempty** returnerar True om kön är tom
- ▶ **Insert** stoppar in ett element i kön
- ▶ **Inspect-first** returnerar värdet på elementet med högst prioritet i kön
- ▶ **Delete-first** tar bort elementet med högst prioritet i kön
- ▶ **Kill** lämnar tillbaka alla resurser

Fråga

- Hur hanteras element med **samma** prioritet?

Formell specifikation av prioritetskö

OBS! Fel i boken!

```
Ax 1 lsempy (Empty)
Ax 2  $\neg$ lsempy (Insert (v, p))
Ax 3 Inspect-first (Insert (v, Empty)) = v
Ax 4 Inspect-first (Insert (v1, Insert (v2, p))) =
    if v1 R v2
    then Inspect-first (Insert (v1, p))
    else Inspect-first (Insert (v2, p))
Ax 5 Delete-first (Insert (v, Empty)) = Empty
Ax 6 Delete-first (Insert (v1, Insert (v2, p))) =
    if v1 R v2
    then Insert (v2, Delete-first (Insert (v1, p)))
    else Insert (v1, Delete-first (Insert (v2, p)))
```

- Frågor:
 - Om R är “<” och två **lika** värden stoppas in, vilket plockas ut **först**?
 - Dito om R är “≤”.

Exempel (1)


- För val=heltal, $R=<$, dvs. “ $a R b$ ” är sann om $a < b$:
- $p \leftarrow \text{Empty}()$




- $p \leftarrow \text{Insert}(25, p)$




- $p \leftarrow \text{Insert}(15, p)$



- $p \leftarrow \text{Insert}(20, p)$




- $p \leftarrow \text{Insert}(15, p)$



Exempel (2)


- För val=3-tippel med (name, age, sex),
 - $R = a.\text{age} < b.\text{age}$:



Exempel (3)

- För val=3-tippel med (name, age, sex)

- $R = F \ R \ M$ (kvinnor prioriteras före män):



Stack och Kö som specialfall av Prioritetkö

- Om R är en **strikt partiell ordning**, t.ex. $>$, kommer **lika** element behandlas som en **kö**
- Om R är **icke-strikt** partiell ordning, t.ex. \geq , behandlas lika element som en **stack**
- Om R är den **totala relationen**, dvs. sann för alla par av värden blir prioritetkön en **stack**
- Om R är den **tomma relationen**, dvs. falsk för alla par av värden, blir prioritetkön en **kö**

Fråga

- Hur lagras elementen **internt** i prioritetkön?


Konstruktioner av Prioritetkö

- Utgår ofta från konstruktioner av:
 - Mängd
 - Lista eller
 - Hög


Prioritetskö som osorterad lista

- ▶ val=heltal, $R="<":$

- ▶ Insert: $O(1)$




- ▶ Inspect-First, Delete-first: $O(n)$




Prioritetskö som sorterad lista

- ▶ val=heltal, $R="<":$

- ▶ Insert: $O(n)$



- ▶ Inspect-first, Delete-first: $O(1)$




Hög (heap), informellt

- ▶ En Hög (heap) är ett **partiellt sorterat binärt träd**
- ▶ I en Hög så ligger det viktigaste elementet **överst**
 - ▶ Det gäller **rekursivt**
 - ▶ Varje delträd är också en Hög

Hög, formellt


- ▶ Ett binärt träd **är en Hög** eller har **hög-egenskapen** för en relation R om och endast om:
 - ▶ Trädet är sorterat så att etiketterna för alla föräldra-barn-par uppfyller $p R c$, där p är föräldraetiketten och c är barnetiketten
- ▶ Exempel: Är följande träd en Heap med $R <?$



- ▶ Insättningar och borttagningar blir **effektiva** om dom görs så att trädet hålls **komplett**

Heap — Algoritm för insättning


1. Sätt in det nya elementet på den **första lediga platsen**
2. **Sortera om** grenen tills trädet är en Hög
 - ▶ Exempel: Sortera in 10:
 - ▶ Exempel: Sortera in 30:



- ▶ Komplexitet för insättning av **ett** element i en Hög med n element?
 - ▶ $O(\log n)$

Heap — Algoritm för borttagning

1. Ta bort **toppelementet**
 2. Flytta **sista** elementet till toppen
 3. Om nödvändigt,
 - 3.1 Byt ut toppelementet mot det **minsta** av dess barn
 - 3.2 **Fortsätt nedåt** i den påverkade grenen
- ▶ Exempel: Remove-first:



- ▶ Komplexitet för borttagning av ett element i en Hög med n element?
 - ▶ $O(\log n)$

Komplexitet för olika konstruktioner av Prioritetsskö

	Insättning	Avläsning	Borttagning
Lista	$O(1)$	$O(n)$	$O(n)$
Sorterad lista	$O(n)$	$O(1)$	$O(1)$
Hög	$O(\log n)$	$O(1)$	$O(\log n)$

Tillämpningar

- ▶ Operativsystem som fördelar jobb mellan olika processer
- ▶ Enkelt sätt att sortera något:
 - ▶ Stoppa in allt i en heap och plocka ut det igen — **heapsort**
- ▶ Hjälpmedel vid traversering av **graf**:
 - ▶ Jfr **stack** och **kö** används vid traversering av **träd**